Aula 002 - Exercícios

Alunos: Bruno Valério Abrahim, Leonardo Xavier Rodrigues, Gabriel Rodrigues Soares

1 Conceitual – Importância da Preparação

Explique por que a etapa de preparação de dados pode impactar mais o desempenho de um modelo do que a escolha do algoritmo de Machine Learning.

Resposta:

A etapa de preparação de dados pode impactar mais o desempenho de um modelo do que a escolha do algoritmo porque é nela que garantimos a qualidade das informações que serão utilizadas no treinamento. Dados com erros, inconsistências, valores faltantes ou ruídos prejudicam diretamente o aprendizado do modelo, fazendo com que ele identifique padrões incorretos ou irrelevantes. Mesmo algoritmos avançados não conseguem compensar dados mal preparados. Por outro lado, quando os dados são bem tratados, limpos e organizados, até modelos mais simples conseguem apresentar bons resultados, pois aprendem padrões mais fiéis à realidade.

2 Valores Ausentes

Considere um dataset com 10.000 registros onde 25% das entradas da variável `idade` estão ausentes.

a) Quais são as possíveis estratégias para tratar esses valores?

b) Em quais situações remover registros é inadequado?

Resposta:

Existem várias estratégias para tratar valores ausentes em um dataset. Uma possibilidade é remover os registros que possuem dados faltantes, mas isso só é viável quando a quantidade de valores ausentes é pequena. Outra abordagem comum é preencher esses valores, utilizando média ou mediana para variáveis numéricas e moda para variáveis categóricas. Também é possível utilizar técnicas mais sofisticadas, como interpolação ou modelos de imputação, além de criar uma categoria específica como “desconhecido”.

Remover registros se torna inadequado quando a quantidade de dados faltantes é significativa, como no caso apresentado de 25%. Nessa situação, a exclusão pode causar perda relevante de informação e até introduzir viés no modelo. Também não é recomendado remover quando o dataset já é pequeno ou quando a ausência de dados possui significado importante dentro do problema.

3 Normalização vs Padronização

Explique a diferença entre:

- Normalização (Min-Max)
- Padronização (Z-score)

Em quais tipos de algoritmos cada uma é mais recomendada? Justifique.

Resposta:

A normalização e a padronização são técnicas de escalonamento de dados, mas possuem diferenças importantes. A normalização, também conhecida como Min-Max, transforma os valores para um intervalo fixo, geralmente entre 0 e 1. Já a padronização transforma os dados de forma que tenham média igual a zero e desvio padrão igual a um.

A normalização é mais indicada para algoritmos que dependem de distância, como KNN e redes neurais, pois mantém os dados em uma escala uniforme. No entanto, ela é sensível a outliers. A padronização, por sua vez, é mais robusta nesse aspecto e costuma ser recomendada para algoritmos como regressão linear, regressão logística e SVM, que assumem distribuições mais próximas da normal.

4 Dados Categóricos

Você possui a variável:

Código

```
clima = {sol, chuva, nublado}
```

a) Como transformar essa variável para uso em um modelo de Machine Learning?

b) Qual problema pode ocorrer se utilizarmos apenas codificação numérica simples (0,1,2)?

Resposta:

Para utilizar a variável categórica “clima”, com valores como sol, chuva e nublado, em um modelo de Machine Learning, é necessário transformá-la em formato numérico. A forma mais adequada, nesse caso, é o uso de One-Hot Encoding, que cria uma coluna para cada categoria e representa cada valor com combinações de zeros e uns.

Utilizar uma codificação numérica simples, como 0, 1 e 2, pode causar problemas porque introduz uma ordem artificial entre as categorias. O modelo pode interpretar que existe uma relação de maior ou menor entre os valores, o que não faz sentido para esse tipo de variável e pode prejudicar o aprendizado.

5 Overfitting e Separação de Dados

Explique por que dividimos o dataset em:

- Treino
- Validação
- Teste

O que acontece se utilizarmos o conjunto de teste durante o treinamento?

Resposta:

Dividimos o dataset em conjuntos de treino, validação e teste para garantir que o modelo seja avaliado de forma justa e consiga generalizar para novos dados. O conjunto de treino é utilizado para ensinar o modelo, o de validação serve para ajustar parâmetros e tomar decisões durante o desenvolvimento, e o de teste é usado apenas ao final para medir o desempenho real.

Se utilizarmos o conjunto de teste durante o treinamento, o modelo acaba se ajustando a esses dados, o que compromete a avaliação. Isso gera métricas irreais, pois o modelo já “conhece” os dados de teste, caracterizando overfitting e reduzindo sua capacidade de generalização.

6 Balanceamento de Classes

Considere um problema onde:

- 95% das amostras pertencem à classe A
- 5% pertencem à classe B

a) Qual problema pode ocorrer?

b) Cite duas técnicas para tratar esse desbalanceamento.

Resposta:

Quando há um grande desbalanceamento entre classes, como 95% para a classe A e 5% para a classe B, o modelo tende a favorecer a classe majoritária. Isso pode resultar em uma alta acurácia aparente, mas com baixo desempenho na identificação da classe minoritária, que muitas vezes é a mais importante.

Para tratar esse problema, podem ser utilizadas técnicas como oversampling, que aumenta artificialmente a quantidade de dados da classe minoritária, e undersampling, que reduz a quantidade de dados da classe majoritária. Também é possível ajustar pesos das classes no modelo, dando mais importância à classe minoritária durante o treinamento.

7 Detecção de Outliers

Explique:

a) O que são outliers

b) Quando removê-los pode prejudicar o modelo

c) Um método estatístico para detectá-los

Resposta:

Outliers são valores que se distanciam significativamente do padrão dos dados. Eles podem surgir por erros de coleta ou representar eventos raros, mas reais. Em alguns casos, removê-los pode melhorar o desempenho do modelo, mas isso nem sempre é adequado. Quando esses valores representam informações importantes, como fraudes ou comportamentos extremos, sua remoção pode prejudicar o modelo.

Um método estatístico comum para detectar outliers é o Z-score, que mede o quanto um valor se afasta da média em termos de desvio padrão.

Valores com Z-score muito alto ou muito baixo, geralmente acima de 3 ou abaixo de -3, são considerados potenciais outliers.

8 Feature Engineering

Dado o dataset:

Código

```
data_nascimento
```

Explique por que criar a variável `idade` pode ser melhor do que usar diretamente a data de nascimento.

Resposta:

Criar a variável idade a partir da data de nascimento é mais eficiente do que utilizar diretamente a data. Isso ocorre porque a idade já representa de forma direta uma informação relevante para o modelo, enquanto a data de nascimento exigiria que o modelo aprendesse a extrair esse significado. Além disso, a idade é mais fácil de interpretar e reduz a complexidade dos dados, facilitando o aprendizado.

9 Pipeline de Pré-processamento

Descreva um pipeline completo de preparação para um dataset que contém:

- Valores ausentes
- Dados categóricos
- Variáveis com escalas diferentes
- Classes desbalanceadas

Resposta:

Um pipeline completo de pré-processamento começa com a limpeza dos dados, removendo duplicações e corrigindo inconsistências. Em seguida, é feito o tratamento de valores ausentes, utilizando técnicas de imputação adequadas. Depois disso, as variáveis categóricas são convertidas para formato numérico, geralmente com One-Hot Encoding.

Na sequência, é importante tratar possíveis outliers e aplicar técnicas de escalonamento, como normalização ou padronização, dependendo do algoritmo utilizado. Caso haja desbalanceamento de classes, técnicas específicas são aplicadas para corrigir esse problema. Por fim, o dataset é dividido em conjuntos de treino, validação e teste, garantindo uma avaliação confiável do modelo.

10 Estudo de Caso Aplicado

Você recebeu um dataset para prever aprovação em crédito bancário.

Variáveis:

- renda_mensal
- idade
- estado_civil
- número_de_dependentes
- histórico_de_inadimplência

Descreva todas as etapas de preparação antes de treinar o modelo.

Seja específico.

Ao receber um dataset para prever aprovação de crédito bancário, o primeiro passo é realizar a limpeza dos dados, removendo duplicatas e verificando valores inconsistentes, como idades inválidas ou rendas incoerentes. Em seguida, é necessário tratar valores ausentes, utilizando estratégias como preenchimento por média, mediana ou moda, dependendo da variável.

Depois disso, pode-se aplicar feature engineering, criando novas variáveis como renda por dependente ou agrupamentos de faixa etária. As variáveis categóricas, como estado civil, devem ser convertidas para formato numérico por meio de codificação adequada.

Também é importante analisar a presença de outliers, especialmente em renda, decidindo se devem ser mantidos ou ajustados. Em seguida, aplica-se escalonamento nas variáveis numéricas e verifica-se se há desbalanceamento entre classes, aplicando técnicas de balanceamento se necessário.

Por fim, o dataset é dividido em treino, validação e teste, garantindo que o modelo seja treinado corretamente e avaliado de forma justa antes de sua utilização prática.